


顶级大厨与传统的点菜方式



顶级大厨 (The LLM)

为了得到特定的口味，我们过去使用**硬提示 (Hard Prompt)**：像是在纸条上写下死板的指令 'Please make it spicy'。



自然语言交互

我们将模型视为人类，通过**离散的语言**进行交互。但这就像是一个只有几个档位的开关，**不够精准**。

与其写纸条，不如直接进厨房调整味道。



概念一：输入嵌入矩阵 (X)

把食材变成大厨能懂的分子结构式

The Transformation



原始文本 (Raw Text)



数学表征 (Mathematical Representation)

The Math

今天天气不错

[Token IDs: 104, 552, 993...]

$$\begin{matrix} & & \mathbf{X} & & \\ \begin{bmatrix} -0.0(1) & -0.8(6) & \dots & 0.2(1) & 0.0(1) \\ -0.2(4) & -0.1(4) & \dots & 0.2(4) & 0.3(4) \\ -0.3(5) & -0.2(3) & \dots & -0.8(5) & 0.1(5) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ -0.0(3) & -0.3(3) & \dots & 0.1(1) & 0.0(3) \\ -0.1(3) & -0.9(4) & \dots & -0.2(4) & -0.1(3) \end{bmatrix} & \begin{matrix} \text{Coordinate Vector} \end{matrix} \end{matrix}$$

模型不读文字，只读数字。这些向量拼在一起构成了**输入嵌入矩阵**。

概念二：软提示嵌入矩阵 (P)

一包没有名字的神奇调料



不再写“翻译”二字，而是扔入一包**无名调料**。
虽然人类看不懂，但大厨秒懂。

P
(Soft Prompt)

$p_{1,1}$	$p_{1,2}$	$\dots$	$p_{1,n}$
$p_{1,1}$	$p_{1,2}$	$\dots$	$p_{2,4}$
$p_{1,1}$	$p_{1,2}$	$\dots$	$p_{3,6}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$
$p_{2,1}$	$p_{2,2}$	$\dots$	$p_{n,n}$
$p_{1,1}$	$p_{1,2}$	$\dots$	$p_{n,n}$

X

-0.0(1)	-0.8(6)	$\dots$	0.2(1)	0.0(1)
-0.2(4)	-0.1(4)	$\dots$	0.2(4)	0.3(4)
-0.3(5)	-0.2(3)	$\dots$	-0.8(5)	0.1(5)
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
-0.0(3)	-0.3(3)	$\dots$	0.1(1)	0.0(3)
-0.1(3)	-0.9(4)	$\dots$	-0.2(4)	-0.1(3)

Coordinate Vector

Model Input

可训练参数 (Trainable Parameters)

这是一个长度为 20 左右的向量组。它们是**抽象的数学特征**，专为模型内部逻辑优化，而非为人类阅读设计。其他专为模型内部逻辑优化，而非为人类阅读。

概念三：连续可微分的张量

精确到 0.0001 克的调味权



离散 (Discrete)

- 语言是断裂的。无法计算‘翻译 + 0.1’的梯度。




连续可微分 (Continuous Differentiable)

- 软提示是连续的向量空间。我们可以计算 ∇_d 梯度 (Gradient)，像无级旋钮一样丝滑地调整数值，找到全局最优解。

寻找完美的味道：优化空间对比


硬提示 (Hard Prompts)



离散空间 (Discrete Space)

只能在有限的词汇中跳跃，容易错过最佳点。

软提示 (Soft Prompts)




连续流形 (Continuous Manifold)

通过梯度下降 (Gradient Descent)，我们可以顺滑地滑动到全局最优解 (Global Optimum)。

概念四：反向传播 (Backpropagation)


只改调料，不改大厨



当结果不理想时，我们计算 Loss。
因为大厨是大参数模型，被冻结了。
纠错信号（梯度）只会用来调整软提示矩阵（ P ）的数值。
这叫：**Parameter Efficiency**。

软提示微调的全流程 (The Complete Workflow)

1. 拼接输入
($P + X$)



2. 前向传播
(Frozen Model)



3. 输出预测
(Output)



4. 计算损失
(Loss Calculation)



5. 反向传播更新 P
(Backprop & Update)

我们构建了一个闭环：将不可微的自然语言任务，转化为可微的数学参数优化问题。

喂给机器的直觉



Soft Prompt Tuning不
仅仅是一种技术，更是
一种哲学转变。

- **高效 (Efficient)**：以极小的参数代价撬动巨大的模型能力。
- **本质 (Essence)**：不再是用人类语言去“命令” AI，而是直接注入数学直觉。

“一套给大模型喂数学‘迷魂汤’而非人类语言指令的机制。”