


代理微调：大模型黑盒操控术

不改参数、不碰黑盒，如何实现“隔山打牛”？



微调的三重境界

Prompt-tuning


加在输入 (Input)



递纸条

Adapter / LoRA


加在模型 (Model)



微创手术

Proxy-tuning


加在输出 (Output)



隔山打牛

传统微调面临的两只“拦路虎”


硬件之墙 (The Hardware Wall)



模型太大了，装不下

LLaMA-70B 这种巨兽，消费级 GPU 根本跑不动。

黑盒之锁 (The Black Box Lock)

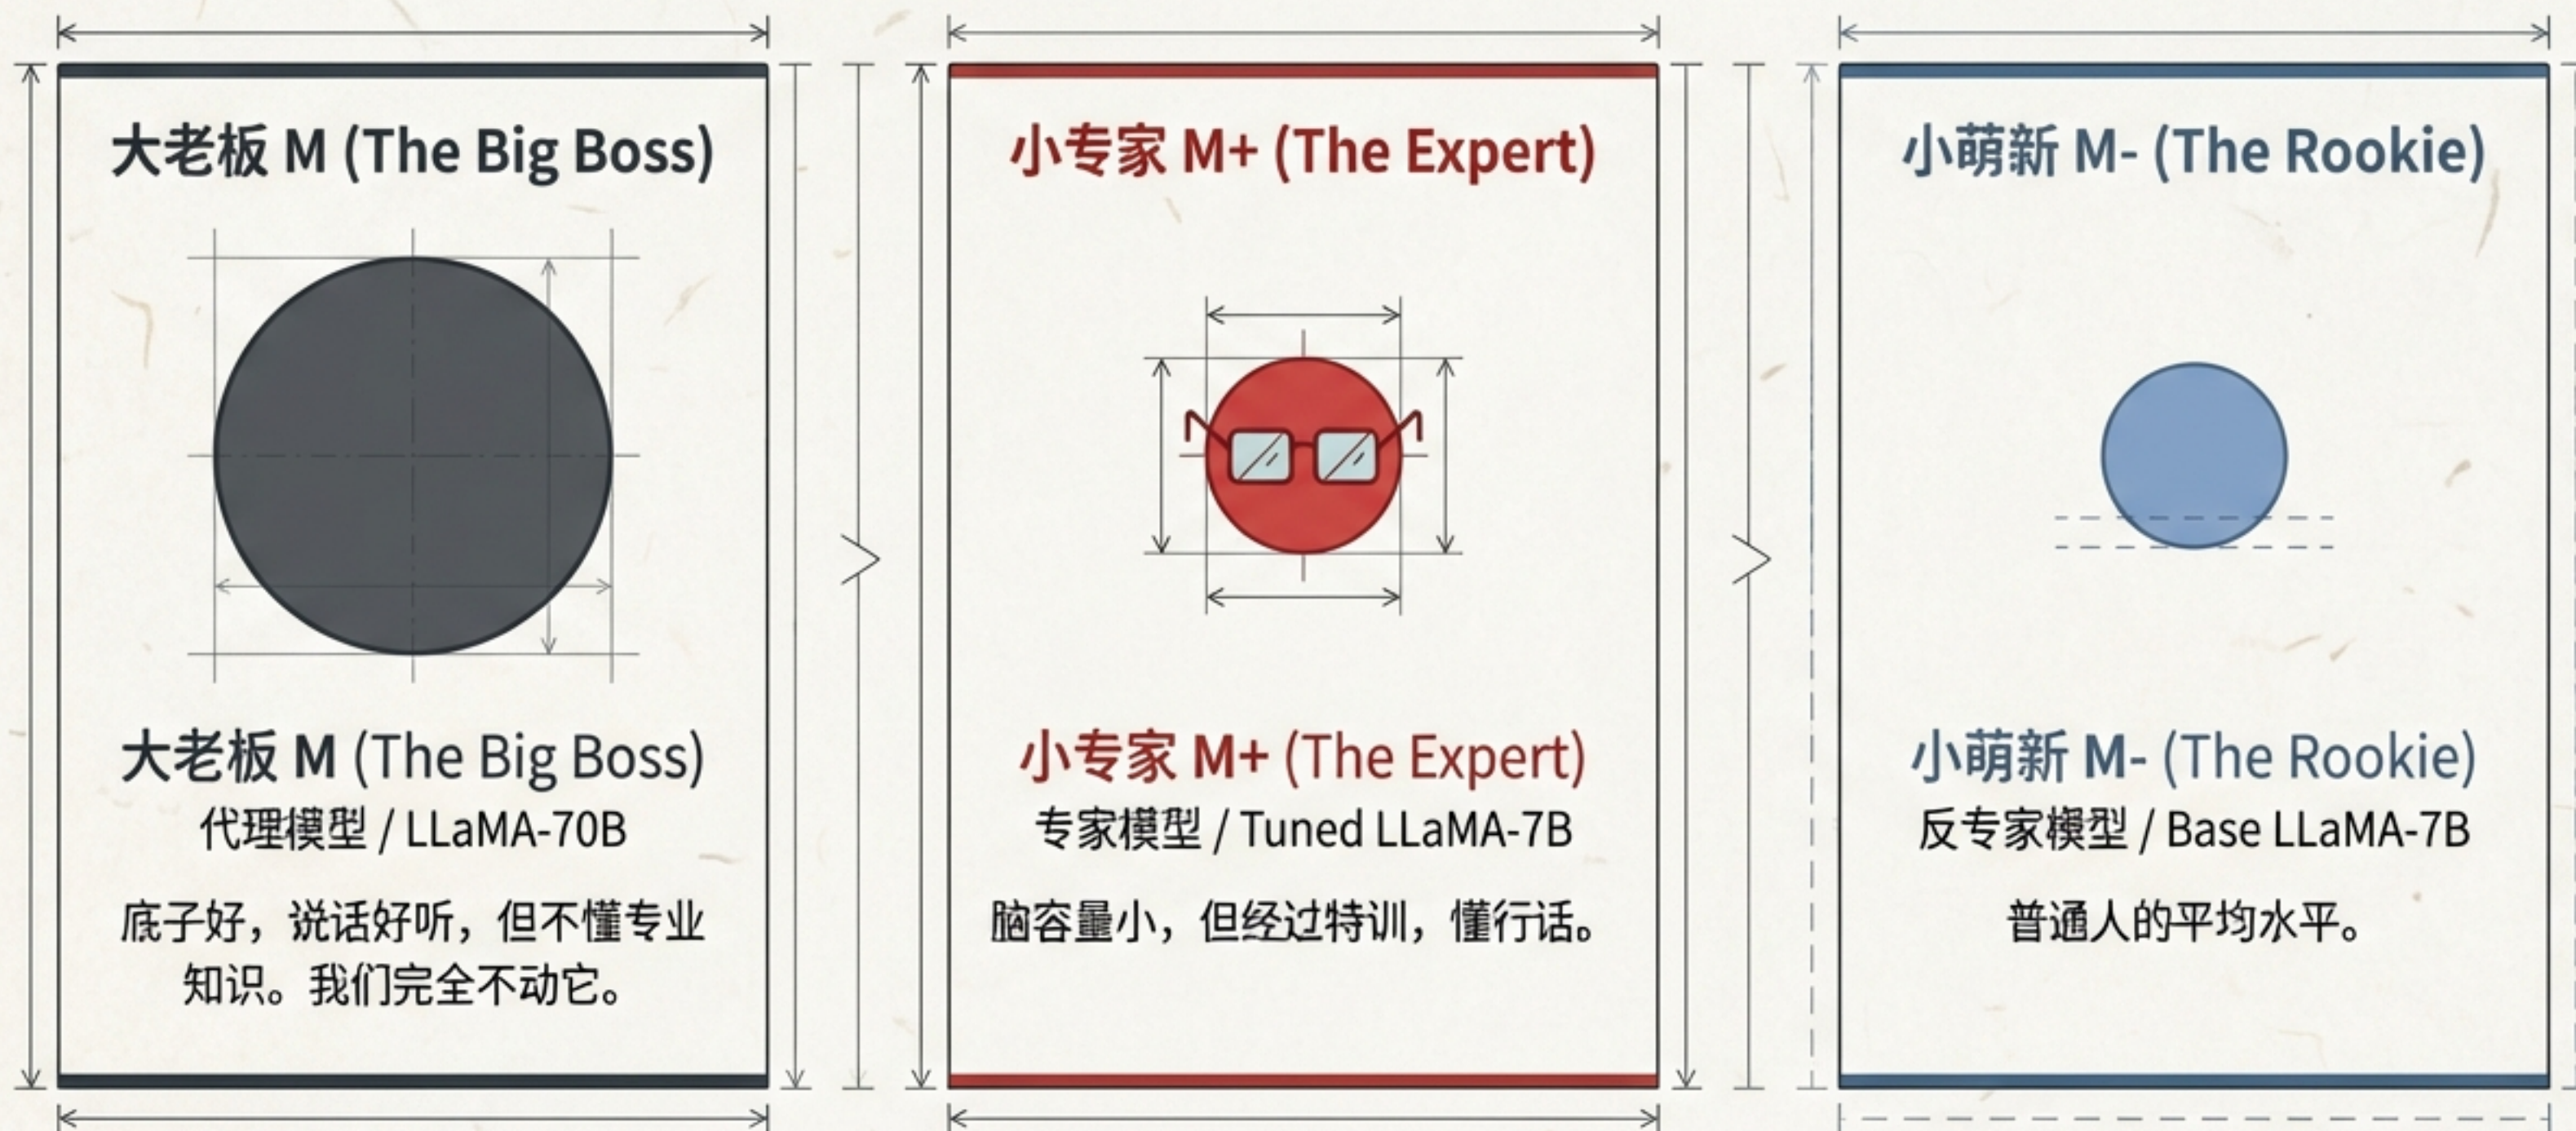


模型是黑盒，碰不到

GPT-4 等商业模型不开源权重。想改参数？门都没有。


解决方案：不需要修改权重，在解码瞬间施加外力修正。

演员阵容：三个和尚有水喝



关键约束：必须同声同气

Tokenizer / 词表




共享字典 (Shared Vocabulary)


这三个模型必须共用同一套字典，否则就像鸡同鸭讲，没法配合。

第一步：小模型们的秘密辩论

当被问及金融问题时...



第二步：提取“专家滤镜”



$$\text{Expert Filter} = (s_{M+} - s_{M-})$$

我们将小专家的分數減去小萌新的分數。
這個差值，代表了‘只有受過特訓才懂的知识’。

第三步：给大老板“施法”



$$Final = M + Filter$$

大老板被加上‘金融滤镜’后，
嘴里不由自主地蹦出了专业的‘股票’二字。

原理解析：为什么能操控黑盒？

权重 (Weights) - 不可访问



输出层 (Logits) - 可加减

我们不需要碰权重，只需要操作输出端的概率分布。
只要大老板愿意告诉我们每个字的概率，我们就能通过加减法控制它。

代理微调的核心优势



轻量级
(Lightweight)

只需要训练那个小小的“小专家”，成本极低。



黑盒友好
(Black-box Friendly)

完全不需要访问内部权重。



知识迁移
(Knowledge Transfer)

把小模型的“专业知识”，嫁接到
大模型的“高超表达”上。

一句话总结

代理微调就是——用小模型的‘专业见解’，去修正大模型的‘发言稿’，让大模型在不用重新学习的情况下，立马变身行业专家。

