



大模型参数附加微调：小成本适配之道

告别“开颅手术”，打造大模型的高效“外骨骼”




全量微调 (Full Fine-Tuning)



⚠ 风险大、成本高


相当于对模型进行“开颅手术”。不仅算力成本高昂，还容易破坏模型原有的通用能力。

参数附加 (Addition-based Methods)




🛡 冻结原始参数

核心原则是 **绝对不碰** 原本的几百亿个参数。我们在模型的脑子外面、里面或后面，强行塞进小小的、可训练的新模块。




Takeaway: 保持原有知识不变 + 学会新技能 = 高效适配





Zone 1: 动输入
(The Input Layer)

Zone 2: 动脑子
(The Internal Layers)


Zone 3: 动输出
(The Output Layer)



根据“手术部位”
的不同，我们将
高效微调分为
三大流派。





第一招：动输入（Prompt-tuning）— 给模型贴一张无形的便利贴




机器更喜欢数学语言。
我们不再用人类语言写
指令，而是插入一串
“**可学习的连续向量**”。

对人类来说是乱码，对模
型来说是最高效的指令。

Mechanism Note:
大模型参数保持不动，只
调整这串“乱码”的数值。




Prompt-tuning 的核心优势：一个模型，万种分身



STORAGE:

极其省地儿：
存储一个任务的 Prompt
仅需几 KB（对比
全量微调的 GB 级）。



AGILITY:

Task Switching:
像换便利贴一样切换
任务，实现快速迭代。




SCALING:

Performance Note:
越大越强 —— 模型参数
量越大，Prompt-tuning
的效果越接近全量微调。




第二招：动脑子 (Prefix-tuning) — 潜意识植入




“虚假记忆”

就像在每一层潜意识里植入提示，诱导模型往特定方向思考。



Difference:


不同于 Prompt-tuning 只在输入层，Prefix-tuning 深入每一层注意力模块。




MLP Trick:

过河拆桥：训练时用简单的神经网络（MLP）生成前缀以保证稳定，训练完丢弃 MLP，只保留参数。

第二招：Adapter-tuning — 这里的“三明治”结构




为什么省钱？解密“瓶颈结构” (The Bottleneck Architecture)



中间窄意味着参数极少 ($r \ll d$)。只训练中间这一小撮参数，就能起到四两拨千斤的效果。

AdapterFusion —— 技能融合的“圆桌会议”

当我们需要模型同时具备翻译、写诗、代码能力时怎么办？




- 第一阶段：各练各的 (Train individual adapters)。
- 第二阶段：开会融合 (Fuse)。🔒 固定住模型和适配器，✍️ 专门训练“融合层”。

第三招：动输出（Proxy-tuning）——隔山打牛的黑盒魔法

面对GPT-4这种不公开参数的黑盒模型，或者显卡装不下大模型时，无法进行内部修改。


MULTI-HEAD
ATTENTION BLOCK



找两个小弟（小模型）来控制大哥（大模型）。

代理微调的工作原理


$$\$Prediction_{final} = Prediction_{BigModel} + (Prediction_{Expert} - Prediction_{Amateur})$$



MULTI-HEAD
ATTENTION BLOCK



1. 我们在生成每一个字时，计算 $M+$ 和 $M-$ 的预测差异。



2. 这个差异代表了“专业知识”。



3. 将这个差异直接叠加在大哥的预测上。

“自带翻译器”

大哥虽然没学过，但被迫带上了专家小弟的“滤镜”，输出结果瞬间变专业。



Expert Filter
(专家小弟的滤镜)



大哥
(Big Brother)

专业输出
(Professional Output)

全景回顾：哪种“手术”适合你？

流派 (Method)	部位 (Location)	通俗理解 (Metaphor)	核心特点 (Key Characteristic)
Prompt-tuning	输入层 (Input)	便利贴 (Sticky Note) 	 极其轻量，适合大规模扩展。 
Prefix-tuning	内部 (Attention)	 潜意识 (Implant) 	 优化“记忆”，  使用MLP技巧。
Adapter-tuning	内部 (Layers)	 三明治 (Sandwich) 	 瓶颈结构，高度  模块化。
Proxy-tuning	输出层 (Output)	 遥控器 (Remote Control)	 作用于黑盒，无  需访问权重。

MULTI-HEAD
ATTENTION BLOCK

小成本办大事 (Small Cost, Big Impact)

我们的目标是在大模型
用最小的代价让它动起来。

这个庞然大物保持静止（冻结参数）的情况下，

Enion Module

Brain Cell

Excekeleton Modules

Brain Brain

JetBrains Mono

MULTI-HEAD
ATTENTION BLOCK

“Freeze the Giant, Train the Expert.” (冻结巨人，训练专家)